

Laporan Akhir Proyek
Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Alya Nabila Tamam 24031554099
Anggota 1	Fina Nihayatul Husna 2431554022
Anggota 2	Juli Yawati Manalu 24031554050
URL Github	https://github.com/alyanabilatamam/Projek-Machine-Learning

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Daun Padi Menggunakan Ekstraksi Fitur MobileNetV3 dan Random Forest untuk Mendukung Pertanian Berkelanjutan
Topik	Pangan
Pilihan Rumusan Masalah	1.3 Dampak Perubahan Iklim dan Rendahnya Adopsi Pertanian Berkelanjutan

Pendahuluan	
Latar belakang	Padi (<i>Oryza sativa</i> L.) merupakan salah satu komoditas pangan utama yang memiliki peran strategis dalam menjaga ketahanan pangan masyarakat Indonesia. Sebagai negara agraris dengan lebih dari 7 juta hektar lahan sawah, Indonesia sangat bergantung pada produktivitas sektor pertanian padi untuk memenuhi kebutuhan pangan sekitar 270 juta penduduknya. Namun, produktivitas tanaman padi kerap mengalami penurunan akibat serangan berbagai penyakit daun seperti <i>Rice Blast</i>, <i>Brown Spot</i>, <i>Bacterial Leaf Blight</i>, <i>Leaf Scald</i>, dan <i>Hispa</i> yang dapat menyebabkan kerusakan tanaman serta menurunkan hasil panen secara signifikan [5], [7]. Permasalahan ini menjadi semakin kritis seiring dengan dampak perubahan iklim global yang memengaruhi pola curah hujan, peningkatan suhu rata-rata, dan ketidakstabilan kelembapan udara di berbagai wilayah pertanian Indonesia. Kondisi lingkungan yang tidak menentu tersebut menciptakan ekosistem yang kondusif bagi perkembangan patogen tanaman, sehingga risiko penyebaran penyakit daun padi menjadi semakin tinggi dari tahun ke tahun [9]. Dampak yang ditimbulkan tidak hanya memengaruhi produktivitas dan kualitas hasil pertanian, tetapi juga berpotensi mengganggu ketahanan pangan nasional serta meningkatkan kerugian ekonomi para petani. Proses identifikasi penyakit daun padi yang berlaku saat ini masih banyak dilakukan secara manual melalui pengamatan visual langsung oleh petani atau tenaga

	ahli pertanian. Metode konvensional ini membutuhkan pengalaman bertahun-tahun dan ketelitian yang sangat tinggi, serta memerlukan waktu yang relatif lama [4]. Di banyak wilayah pertanian terpencil di Indonesia, keterbatasan tenaga ahli agronomis menyebabkan proses diagnosis penyakit tidak dapat dilakukan secara tepat waktu, sehingga penanganan tanaman sering terlambat dilakukan. Kesalahan identifikasi penyakit pun berdampak pada penggunaan pestisida yang tidak tepat sasaran, yang selanjutnya meningkatkan biaya produksi dan menyebabkan pencemaran lingkungan pertanian [9]. Berbagai penelitian mengenai klasifikasi penyakit tanaman berbasis <i>machine learning</i> dan <i>deep learning</i> telah banyak dilakukan [1], [2], [5], [7]. Namun masih terdapat sejumlah tantangan dalam penerapannya di kondisi nyata. Variasi kondisi citra, perbedaan resolusi gambar, pencahayaan, latar belakang, dan sudut pengambilan foto, serta distribusi data yang tidak seimbang (<i>class imbalance</i>) antar kelas penyakit menjadi hambatan utama yang memengaruhi performa model klasifikasi [4], [10]. Selain itu, model <i>deep learning</i> dengan kompleksitas tinggi umumnya membutuhkan sumber daya komputasi yang besar, sehingga kurang efisien untuk diterapkan pada perangkat dengan spesifikasi terbatas [3]. Berdasarkan latar belakang tersebut, penelitian ini mengusulkan penggunaan ‘MobileNetV3’ sebagai <i>feature extractor</i> [3] dan ‘Random Forest’ sebagai <i>classifier</i> [4] untuk melakukan klasifikasi penyakit daun padi secara otomatis. Kombinasi kedua metode ini dirancang untuk menghasilkan model yang akurat, efisien secara komputasi, dan ringan, sehingga dapat mendukung penerapan pertanian cerdas (<i>smart agriculture</i>) dan pertanian berkelanjutan di Indonesia.
Rumusan masalah dan tujuan	Berdasarkan latar belakang penelitian, rumusan masalah dalam penelitian ini adalah sebagai berikut: 1. Bagaimana mengembangkan model klasifikasi penyakit daun padi yang akurat menggunakan kombinasi ‘MobileNetV3’ sebagai <i>feature extractor</i> dan ‘Random Forest’ sebagai <i>classifier</i>? 2. Seberapa efektif penggunaan <i>transfer learning</i> ‘MobileNetV3’ dalam menghasilkan representasi fitur visual daun padi yang dapat digunakan untuk proses klasifikasi multikelas? 3. Bagaimana performa model ‘MobileNetV3’ dan ‘Random Forest’ dalam mengklasifikasikan 18 kelas penyakit daun padi berdasarkan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, dan <i>F1-Score</i>? 4. Faktor-faktor apa yang memengaruhi keberhasilan maupun kesalahan model dalam mengklasifikasikan berbagai jenis penyakit daun padi? Berdasarkan rumusan masalah yang telah disusun, tujuan dari penelitian ini adalah sebagai berikut:

	1. Mengembangkan model klasifikasi penyakit daun padi menggunakan kombinasi ‘MobileNetV3’ sebagai <i>feature extractor</i> dan ‘Random Forest’ sebagai <i>classifier</i> untuk mengidentifikasi 18 kelas penyakit daun padi. 2. Menganalisis efektivitas penggunaan <i>transfer learning</i> ‘MobileNetV3’ dalam menghasilkan representasi fitur visual yang dapat mendukung proses klasifikasi penyakit daun padi. 3. Mengevaluasi performa model klasifikasi berdasarkan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, F1-Score, dan <i>confusion matrix</i> pada data validasi dan data uji. 4. Menganalisis faktor-faktor yang memengaruhi performa model, termasuk karakteristik dataset, kemiripan visual antar kelas penyakit, serta kontribusi fitur hasil ekstraksi terhadap proses klasifikasi.
--	--

Metodologi

Ringkasan dataset

Dataset yang digunakan dalam penelitian ini bersumber dari repositori publik Kaggle dengan judul [Rice Leaf Disease: An Images Dataset](#). Dataset ini merupakan koleksi citra digital daun padi yang dikumpulkan dari berbagai sumber primer (lapangan dan laboratorium) untuk memastikan variasi kondisi pencahayaan dan latar belakang yang representatif [6].


Tabel 1. Karakteristik Dataset

Karakteristik	Detail
Jumlah Total Citra	29.363 citra digital
Jumlah Kelas	18 kelas penyakit dan kondisi daun
Format File	JPG/PNG
Ukuran Input Model	224 x 224 piksel (resize)
Channel Warna	RGB

Distribusi kelas dalam dataset menunjukkan ketidakseimbangan yang signifikan. Kelas *Brown Spot* memiliki jumlah citra terbanyak (4.661 gambar), diikuti oleh *Bacterial Blight* (4.248), dan *Leaf Blast* (3.456). Sebaliknya, beberapa kelas memiliki data yang sangat sedikit, seperti *Sheath Rot* (91), *Bacterial Streak* (99), *Stem Rot* (100), dan *Ragged Stunt Virus* (100). Kondisi *class imbalance* semacam ini merupakan tantangan umum dalam klasifikasi penyakit tanaman yang dapat menyebabkan bias pada model [4], [10].

Tabel 2. Distribusi Kelas Dataset

Kelas Penyakit	Jumlah Citra	Kategori
Brown Spot	4.661	Mayoritas

		Bacterial Blight	4.248	Mayoritas
		Leaf Blast	3.456	Mayoritas
		Tungro	3.228	Mayoritas
		Healthy	2.952	Sedang
		Leaf Scald	2.608	Sedang
		Hispa	2.209	Sedang
		Narrow Born Spot	1.808	Sedang
		Leaf Smut	1.500	Sedang
		Neck Blast	1.322	Minoritas
		Sheath Blight	632	Minoritas
		False Smut	149	Sangat Minoritas
		Sheath Rot	91	Sangat Minoritas
		Bacterial Streak	99	Sangat Minoritas
		Stem Rot	100	Sangat Minoritas
		Ragged Stunt	100	Sangat Minoritas
		Grassy Stunt	100	Sangat Minoritas
		Bakanae	100	Sangat Minoritas
Alur penelitian	 <pre>graph LR; Start([Start]) --> A[Pengumpulan Dataset dan EDA]; A --> B[Preprocessing Data]; B --> C[Augmentasi Data]; C --> D[Ekstraksi Fitur (MobileNetV3)]; D --> E[Pelatihan Model Random Forest]; E --> F[Evaluasi Model]; F --> G[Analisis Hasil]; G --> End([End]);</pre>			
	Gambar 1. Tahapan Pengerjaan 1) Pengumpulan Data dan EDA Dataset citra daun padi diperoleh dari Kaggle. Tahap EDA dilakukan untuk melihat distribusi kelas, visualisasi sampel citra, ukuran gambar, dan mendeteksi kemungkinan <i>class imbalance</i>. 2) Preprocessing Data			

	Seluruh citra diubah ukurannya menjadi 224×224 piksel agar sesuai dengan input MobileNetV3. Selain itu dilakukan normalisasi nilai piksel ke rentang 0-1. Dataset kemudian dibagi menjadi data train, validation, dan test menggunakan <i>stratified split</i>. 3) Augmentasi Data Augmentasi dilakukan pada data train untuk meningkatkan variasi data dan mengurangi risiko overfitting. Teknik augmentasi yang digunakan meliputi rotasi, flip, zoom, shear, dan perubahan brightness. 4) Ekstraksi Fitur (MobileNetV3) Model 'MobileNetV3' <i>pre-trained</i> digunakan sebagai <i>feature extractor</i>. Lapisan akhir model dihapus dan output hasil ekstraksi diubah menjadi <i>feature vector</i> satu dimensi yang merepresentasikan ciri penting dari citra daun padi. 5) Pelatihan Model Random Forest Feature vector hasil ekstraksi 'MobileNetV3' digunakan sebagai input untuk melatih model 'Random Forest' dalam melakukan klasifikasi penyakit daun padi. 6) Evaluasi Model Performa model dievaluasi menggunakan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, <i>F1-Score</i>, <i>macro F1-Score</i>, dan <i>confusion matrix</i> pada data test. 7) Analisis Model Tahap akhir dilakukan analisis terhadap hasil klasifikasi, kesalahan prediksi, serta visualisasi <i>confusion matrix</i> untuk mengetahui performa model pada setiap kelas penyakit.
Proses <i>wrangling</i>	Proses <i>wrangling</i> data mencakup serangkaian tahapan untuk mempersiapkan dataset citra sebelum digunakan dalam proses pelatihan model: a. <i>Loading Dataset</i> Dataset diunduh dari Kaggle menggunakan library '<i>kagglehub</i>' dan diekstrak ke direktori lokal. Struktur folder dataset mengikuti konvensi satu folder per kelas, sehingga pelabelan dapat dilakukan secara otomatis berdasarkan nama folder [6].

```

Load Folder dari Kaggle

path = kagglehub.dataset_download(
    "alamshihab075/rice-leaf-disease-an-images-dataset"
)

print("Dataset berhasil di-download!")
print("Lokasi dataset:", path)

Using Colab cache for faster access to the 'rice-leaf-disease-an-images-dataset' dataset.
Dataset berhasil di-download!
Lokasi dataset: /kaggle/input/rice-leaf-disease-an-images-dataset

Cek Folder

for root, dirs, files in os.walk(path):
    print("Folder:", root)
    print("Subfolder:", dirs)
    break

Folder: /kaggle/input/rice-leaf-disease-an-images-dataset
Subfolder: ['Rice Disease']

Load Dataset

DATASET_DIR = os.path.join(path, "Rice Disease")

IMG_SIZE = (224, 224)
BATCH_SIZE = 32

print(DATASET_DIR)
print(os.listdir(DATASET_DIR))

/kaggle/input/rice-leaf-disease-an-images-dataset/Rice Disease
['Leaf Scald', 'Tungro', 'Hispa', 'Sheath Blight', 'False Smut', 'Bacterial Blight', 'Ragged Stunt Virus', 'Narrow Brown Spot', 'Healthy', 'I

```

Gambar 2. Kode Loading Dataset

Dataset berhasil dimuat dengan total 29.363 citra yang terdiri dari 18 kelas penyakit dan kondisi daun padi. Seluruh informasi nama file dan label kemudian disimpan ke dalam dataframe untuk mempermudah proses analisis dan pemrosesan data selanjutnya.

b. Resize dan Normalisasi Citra

Seluruh citra diubah ukurannya menjadi 224×224 piksel agar seragam dan sesuai dengan arsitektur input MobileNetV3 [3]. Normalisasi dilakukan menggunakan fungsi `preprocess_input` dari MobileNetV3 yang menyesuaikan distribusi nilai piksel dengan standar data pre-trained ImageNet, sehingga proses ekstraksi fitur dapat berjalan lebih optimal [1], [3].

```

DATASET_DIR = os.path.join(path, "Rice Disease")

IMG_SIZE = (224, 224)
BATCH_SIZE = 32

print(DATASET_DIR)
print(os.listdir(DATASET_DIR))

/kaggle/input/rice-leaf-disease-an-images-dataset/Rice Disease
['Leaf Scald', 'Tungro', 'Hispa', 'Sheath Blight', 'False Smut', 'Bacterial Blight', 'Ragged Stunt Virus', 'Narrow Brown Spot', 'Healthy', 'I

```

Gambar 3. Kode Resize Citra

Seluruh citra memiliki ukuran yang seragam yaitu 224×224 piksel dengan format RGB sehingga dapat diproses secara konsisten oleh model 'MobileNetV3' pada tahap ekstraksi fitur.

c. Augmentasi Data

Augmentasi data diterapkan pada data *training* menggunakan *ImageDataGenerator* untuk meningkatkan variasi data dan membantu generalisasi model [2], [8]. Penelitian Chen et al. (2020) [2] menunjukkan bahwa augmentasi data secara signifikan meningkatkan *robustness* model klasifikasi penyakit tanaman. Teknik augmentasi yang diterapkan:

- Rotasi hingga 20 derajat.
- *Horizontal flip* dan *Vertical flip*
- *Zoom* sebesar 20%

- *Shear transformation*
- *Brightness adjustment*

```
train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input,
    rotation_range=20,
    horizontal_flip=True,
    vertical_flip=True,
    zoom_range=0.2,
    shear_range=0.1,
    brightness_range=[0.8,1.2]
)

test_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input
)
```

Gambar 4. Kode Augmentasi

Citra mengalami berbagai transformasi seperti perubahan orientasi, perbesaran, kemiringan, dan tingkat pencahayaan tanpa mengubah karakteristik utama penyakit pada daun. Augmentasi membantu meningkatkan keragaman data latih sehingga model menjadi lebih robust terhadap variasi kondisi citra.

d. *Stratified Split*

Dataset dibagi menjadi tiga subset menggunakan *stratified split* dengan rasio 70:15:15 untuk data *train*, *validation*, dan *test*. Teknik *stratified* memastikan representasi proporsional setiap kelas pada masing-masing *subset*, yang sangat penting pada kondisi *class imbalance* [4], [6].

```
train_df, temp_df = train_test_split(
    df,
    test_size=0.30,
    stratify=df['label'],
    random_state=42
)

val_df, test_df = train_test_split(
    temp_df,
    test_size=0.50,
    stratify=temp_df['label'],
    random_state=42
)

print("Train :", len(train_df))
print("Val  :", len(val_df))
print("Test  :", len(test_df))

Train : 20554
Val   : 4404
Test  : 4405
```

Gambar 5. Kode Split Data

Distribusi kelas pada masing-masing subset yaitu *Train* 20.554 data, *Validation* 4.404 data, dan *Test* 4.405 data. Namun tetap proporsional terhadap distribusi dataset awal sehingga representasi setiap kelas tetap terjaga selama proses pelatihan dan evaluasi model.

Proses rekayasa fitur

Tahapan rekayasa fitur merupakan inti dari pendekatan yang digunakan dalam penelitian ini. Proses ini mengkonversi data citra mentah menjadi representasi numerik yang dapat diproses oleh algoritma *machine learning* klasik [1], [2].

a. *Transfer Learning* dengan ‘MobileNetV3’

‘MobileNetV3’ *Large* dengan bobot *pre-trained* ‘ImageNet’ digunakan sebagai *feature extractor* [3]. Arsitektur ini dipilih karena kemampuannya mengekstraksi representasi fitur visual tingkat tinggi secara efisien tanpa

perlu melatih CNN dari awal. Lapisan klasifikasi akhir dihapus dan digantikan dengan lapisan *Global Average Pooling*, sehingga setiap citra menghasilkan feature vector berdimensi 960 [3].

Alzubaidi et al. (2021) menunjukkan bahwa pendekatan *transfer learning* dari model CNN yang dilatih pada dataset berskala besar seperti ‘ImageNet’ mampu menghasilkan representasi fitur yang efektif untuk berbagai tugas klasifikasi visual, termasuk penyakit tanaman [1]. ‘MobileNetV3’ secara khusus menggunakan teknologi *depthwise separable convolution* dan modul *squeeze-and-excitation* yang menghasilkan representasi fitur visual yang kaya dengan biaya komputasi yang lebih rendah [3]. Rauf et al. (2019) juga mengonfirmasi bahwa fitur yang diekstraksi dari model *pre-trained* sangat berguna untuk klasifikasi penyakit daun bahkan dengan jumlah data yang terbatas [6].

b. *Random Forest Classifier*

Feature vector hasil ekstraksi ‘MobileNetV3’ digunakan sebagai input bagi algoritma ‘Random Forest’. Islam et al. (2022) menyatakan bahwa *Random Forest* merupakan algoritma yang sangat efektif untuk mengolah fitur berdimensi tinggi hasil ekstraksi CNN dalam konteks klasifikasi penyakit daun padi [4]. Sethy et al. (2020) juga membuktikan bahwa kombinasi fitur *deep CNN* dengan klasifikasi berbasis *machine learning* klasik menghasilkan performa yang kompetitif [7]. Model dilatih dengan konfigurasi berikut:

Tabel 3. Konfigurasi *Hyperparameter Random Forest*


Parameter	Nilai	Keterangan
<i>n_estimators</i>	200	Meningkatkan stabilitas prediksi
<i>max_depth</i>	20	Mengontrol kompleksitas model
<i>min_samples_split</i>	5	Mengurangi <i>overfitting</i> pada node
<i>min_samples_leaf</i>	2	Memastikan generalisasi leaf node
<i>class_weight</i>	‘balanced’	Menangani <i>class imbalance</i>
<i>random_state</i>	42	Reprodusibilitas eksperimen
<i>n_jobs</i>	-1	Paralelisasi komputasi penuh

Nilai *hyperparameter* ‘Random Forest’ dipilih berdasarkan beberapa percobaan awal untuk memperoleh keseimbangan antara performa dan kompleksitas model. Parameter ‘*n_estimators=200*’ digunakan untuk meningkatkan stabilitas prediksi, sedangkan ‘*max_depth=20*’ digunakan untuk mencegah model menjadi terlalu kompleks. Parameter

	<i>class_weight='balanced'</i> diterapkan untuk mengurangi pengaruh ketidakseimbangan kelas pada proses pelatihan.
Temuan	Analisis eksplorasi data (EDA) mengungkap beberapa temuan penting mengenai karakteristik dataset citra daun padi yang secara langsung memengaruhi strategi pemodelan yang dipilih. 1. Class Imbalance yang Signifikan Rasio antara kelas terbesar (Brown Spot: 4.661) dan kelas terkecil (Sheath Rot: 91) mencapai sekitar 51:1. Ketidakseimbangan kelas semacam ini dapat menyebabkan model bias terhadap kelas mayoritas [4], [10], dan diatasi melalui penggunaan parameter <i>class_weight='balanced'</i> pada 'Random Forest' serta teknik augmentasi data [2], [8]. 2. Variasi Kondisi Citra Sampel citra menunjukkan variasi yang signifikan dalam hal pencahayaan, sudut pengambilan gambar, dan latar belakang. Variabilitas kondisi citra merupakan salah satu tantangan utama dalam penerapan machine learning untuk fenotipe tanaman di lapangan [9]. 3. Kemiripan Visual Antar Kelas Beberapa jenis penyakit memiliki tampilan visual yang mirip satu sama lain, seperti antara <i>Brown Spot</i> dan <i>Narrow Brown Spot</i>, atau antara <i>Leaf Blast</i> dan <i>Neck Blast</i>. Kemiripan karakteristik visual antar kelas penyakit daun padi merupakan sumber utama kesalahan klasifikasi bahkan pada model CNN yang dalam [5]. Kemudian selama proses pengembangan model, diperoleh beberapa insight penting yaitu : 1. Efektivitas Transfer Learning Penggunaan 'MobileNetV3' <i>pre-trained</i> 'ImageNet' terbukti efektif dalam mengekstraksi representasi fitur visual yang bermakna, bahkan untuk kelas-kelas yang memiliki data sangat sedikit [1], [2]. 2. Keunggulan Random Forest pada Data Berdimensi Tinggi <i>Feature vector</i> berdimensi 960 yang dihasilkan 'MobileNetV3' dapat diproses dengan baik oleh 'Random Forest' berkat kemampuannya menangani data berdimensi tinggi secara intrinsik [4], [7]. 3. Dampak Class Imbalance Kelas-kelas dengan data sangat sedikit (< 150 sampel) menunjukkan performa yang jauh lebih rendah dibandingkan kelas mayoritas, meskipun telah diterapkan <i>class_weight='balanced'</i> [4], [10]. 4. Distribusi Feature Importance Analisis <i>feature importance</i> menunjukkan bahwa fitur terpenting memiliki nilai <i>importance</i> relatif kecil (~ 0.007), mengindikasikan distribusi kontribusi fitur yang cukup merata di antara 960 dimensi [4].

Hasil dan Pembahasan

Hasil eksplorasi data




Gambar 6. Distribusi Jumlah Citra per Kelas

Eksplorasi data diawali dengan menganalisis distribusi jumlah citra pada setiap kelas penyakit daun padi. Hasil visualisasi menunjukkan bahwa dataset terdiri atas 18 kelas dengan jumlah data yang tidak seimbang. Kelas *Brown Spot* memiliki jumlah citra terbanyak yaitu 4.661 citra, diikuti oleh *Bacterial Blight* sebanyak 4.248 citra dan *Leaf Blast* sebanyak 3.456 citra. Sebaliknya, beberapa kelas seperti *Sheath Rot* (91 citra), *Bacterial Streak* (99 citra), *Bakanae* (100 citra), *Stem Rot* (100 citra), *Ragged Stunt Virus* (100 citra), dan *Grassy Stunt Virus* (100 citra) memiliki jumlah data yang sangat sedikit. Kondisi ini menunjukkan adanya *class imbalance* yang berpotensi memengaruhi kemampuan model dalam mengenali kelas-kelas minoritas.



Gambar 7. Sampel Citra Dataset

Visualisasi sampel citra dilakukan untuk memahami karakteristik visual data yang digunakan. Dari beberapa contoh gambar terlihat bahwa dataset memiliki variasi kondisi pencahayaan, warna daun, ukuran objek, dan latar belakang. Selain itu, pola gejala penyakit pada daun juga menunjukkan tingkat keragaman yang cukup tinggi. Variasi tersebut mencerminkan kondisi nyata di lapangan sehingga model klasifikasi dituntut mampu melakukan generalisasi terhadap berbagai kondisi citra.



Gambar 8. Hasil Augmentasi Citra Daun Padi

Augmentasi data diterapkan pada data latih untuk meningkatkan variasi citra dan membantu model memperoleh kemampuan generalisasi yang lebih baik. Berdasarkan Gambar 8, citra mengalami berbagai transformasi seperti rotasi, *flipping*, *zoom*, *shear transformation*, dan penyesuaian tingkat kecerahan (*brightness adjustment*). Meskipun mengalami perubahan posisi dan orientasi, karakteristik utama gejala penyakit pada daun tetap dipertahankan. Teknik ini membantu model mengenali pola penyakit pada berbagai kondisi citra yang mungkin ditemui saat pengujian maupun implementasi di lapangan.

A. Hasil Evaluasi Model

Model klasifikasi penyakit daun padi dikembangkan menggunakan kombinasi ‘MobileNetV3’ *Large* sebagai *feature extractor* dan ‘Random Forest’ sebagai *classifier*. Sebelum proses pelatihan dilakukan, seluruh citra mengalami tahap preprocessing berupa resize menjadi 224×224 piksel dan normalisasi menggunakan fungsi *preprocess_input* sesuai standar ‘MobileNetV3’. Dataset kemudian dibagi menggunakan metode *stratified split* dengan rasio 70% data latih, 15% data validasi, dan 15% data uji untuk menjaga proporsi setiap kelas tetap seimbang.

Pada tahap pelatihan, MobileNetV3 digunakan untuk mengekstraksi fitur visual dari setiap citra sehingga diperoleh *feature vector* berdimensi 960. Fitur hasil ekstraksi tersebut kemudian digunakan sebagai input bagi algoritma Random Forest dengan parameter $n_estimators=200$, $max_depth=20$, $min_samples_split=5$, $min_samples_leaf=2$, dan $class_weight='balanced'$. Proses validasi dilakukan menggunakan data validasi untuk mengevaluasi kemampuan generalisasi model sebelum dilakukan pengujian pada data test. Evaluasi model dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-Score*. Hasil evaluasi pada data validasi dan data test ditunjukkan pada Tabel 4.

Tabel 4. Hasil Evaluasi Model pada Data Validasi dan Test

Metrik	Validation	Test
Accuracy	80.11%	81.68%

Hasil eksperimen

Precision (Macro)	0.85	0.81
Recall (Macro)	0.71	0.71
F1-Score (Macro)	0.73	0.74
Weighted Avg F1	0.80	0.81

Berdasarkan hasil evaluasi tersebut, model berhasil mencapai akurasi sebesar 81.68% pada data test dengan *Macro F1-Score* sebesar 0.74 dalam mengklasifikasikan 18 kelas penyakit daun padi. Hasil ini menunjukkan bahwa kombinasi ‘MobileNetV3’ dan ‘Random Forest’ mampu menghasilkan performa klasifikasi yang cukup baik pada dataset multi-kelas. Selain itu, nilai *accuracy* dan *F1-Score* pada data validasi dan data test relatif konsisten, yang mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik dan tidak mengalami overfitting secara signifikan.

Nilai *Macro Precision* sebesar 0.81 yang lebih tinggi dibandingkan *Macro Recall* sebesar 0.71 menunjukkan bahwa model cenderung lebih berhati-hati dalam memberikan prediksi. Dengan kata lain, model lebih sering menghasilkan prediksi yang benar ketika suatu kelas dipilih, namun masih mengalami kesulitan dalam mengenali seluruh sampel pada beberapa kelas minoritas.

B. Analisis Per Kelas

Analisis per kelas dilakukan untuk memahami performa model pada masing-masing kategori penyakit daun padi. Hasil evaluasi ditampilkan dalam bentuk *classification report* pada Tabel 5.


Tabel 5. Classification Report pada Data Test

Kelas	Precision	Recall	F1-Score	Support
Bacterial Blight	0.86	0.86	0.86	637
Bacterial Streak	0.91	0.67	0.77	15
Bakanae	1.00	0.80	0.89	15
Brown Spot	0.91	0.75	0.82	699
False Smut	0.90	0.86	0.88	22
Grassy Stunt Virus	1.00	0.93	0.97	15
Healthy	0.72	0.86	0.78	443
Hispa	0.75	0.74	0.75	332

Leaf Blast	0.67	0.71	0.68	519
Leaf Scald	0.87	0.83	0.85	391
Leaf Smut	0.84	0.93	0.88	225
Narrow Brown Spot	0.83	0.74	0.78	271
Neck Blast	0.98	1.00	0.99	199
Ragged Stunt Virus	1.00	0.33	0.50	15
Sheath Blight	0.53	0.58	0.56	95
Sheath Rot	0.00	0.00	0.00	13
Stem Rot	1.00	0.56	0.72	15
Tungro	0.89	0.99	0.94	484

Hasil analisis menunjukkan bahwa performa model berbeda pada setiap kelas penyakit. Kelas dengan performa terbaik adalah *Neck Blast* (*F1-Score* 0.99), *Grassy Stunt Virus* (*F1-Score* 0.97), dan *Tungro* (*F1-Score* 0.94). Tingginya performa pada kelas-kelas tersebut menunjukkan bahwa model mampu mengenali karakteristik visual penyakit secara konsisten.

Sebaliknya, beberapa kelas menunjukkan performa yang lebih rendah, seperti *Sheath Rot* (*F1-Score* 0.00), *Ragged Stunt Virus* (*F1-Score* 0.50), dan *Sheath Blight* (*F1-Score* 0.56). Rendahnya performa pada kelas-kelas tersebut dipengaruhi oleh ketidakseimbangan distribusi data. Kelas *Sheath Rot* hanya memiliki 91 citra pada dataset awal dan 13 citra pada data uji, sedangkan *Ragged Stunt Virus* hanya memiliki 100 citra pada dataset awal dan 15 citra pada data uji. Jumlah data yang terbatas menyebabkan model kesulitan mempelajari pola visual yang representatif. Selain itu, beberapa penyakit memiliki karakteristik visual yang mirip, seperti bercak atau perubahan warna daun yang menyerupai penyakit lain, sehingga meningkatkan kemungkinan terjadinya kesalahan klasifikasi.



Gambar 9. Confusion Matrix Model Random Forest

Confusion matrix digunakan untuk menganalisis pola prediksi dan kesalahan klasifikasi yang dilakukan oleh model pada setiap kelas penyakit daun padi. Berdasarkan Gambar 9, sebagian besar nilai terkonsentrasi pada diagonal utama matriks, yang menunjukkan bahwa model mampu mengklasifikasikan sebagian besar sampel ke kelas yang benar. Hal ini sejalan dengan hasil evaluasi yang menunjukkan akurasi sebesar 81,68% dan Macro F1-Score sebesar 0,74.

Kelas-kelas seperti Bacterial Blight, Brown Spot, Neck Blast, dan Tungro menunjukkan jumlah prediksi benar yang tinggi, ditandai dengan intensitas warna yang lebih gelap pada diagonal utama. Hasil tersebut mengindikasikan bahwa model mampu mengenali karakteristik visual penyakit-penyakit tersebut secara konsisten.

Di sisi lain, masih terdapat beberapa kesalahan klasifikasi pada kelas-kelas tertentu, terutama pada kelas minoritas seperti *Sheath Rot*, *Ragged Stunt Virus*, dan *Sheath Blight*. Kesalahan tersebut diduga disebabkan oleh jumlah data yang relatif sedikit serta adanya kemiripan karakteristik visual antar penyakit, sehingga model mengalami kesulitan dalam membedakan pola gejala secara akurat. Temuan ini juga konsisten dengan hasil classification report yang menunjukkan nilai recall dan F1-Score yang lebih rendah pada kelas-kelas tersebut.

Secara keseluruhan, confusion matrix menunjukkan bahwa kombinasi ‘MobileNetV3’ sebagai *feature extractor* dan ‘Random Forest’ sebagai *classifier* telah mampu mempelajari pola visual mayoritas penyakit daun padi dengan baik, meskipun masih terdapat tantangan dalam mengenali beberapa kelas minoritas yang memiliki distribusi data terbatas.

C. Performa Model

Berdasarkan hasil evaluasi, model berhasil mencapai akurasi sebesar 81.68%, *Macro Precision* sebesar 0.81, *Macro Recall* sebesar 0.71, dan *Macro F1-Score* sebesar 0.74. Hasil ini menunjukkan bahwa pendekatan kombinasi ‘MobileNetV3’ sebagai *feature extractor* dan ‘Random Forest’ sebagai *classifier* mampu menghasilkan performa yang baik dalam tugas klasifikasi penyakit daun padi multikelas.

Performa tinggi pada kelas seperti *Neck Blast*, *Grassy Stunt Virus*, dan *Tungro* menunjukkan bahwa penyakit-penyakit tersebut memiliki pola visual yang cukup khas sehingga dapat dikenali dengan baik oleh model. Sebaliknya, performa rendah pada kelas *Sheath Rot*, *Stem Rot*, dan *Ragged Stunt Virus* menunjukkan bahwa jumlah data yang terbatas dan kemiripan visual antar kelas masih menjadi tantangan utama dalam proses klasifikasi.

Jika dibandingkan dengan hasil pada laporan kemajuan, model final menunjukkan peningkatan performa yang cukup signifikan. Akurasi meningkat dari 67.8% menjadi 81.68%, *Precision* meningkat dari 0.75 menjadi 0.81, *Recall* meningkat dari 0.55 menjadi 0.71, dan *F1-Score* meningkat dari 0.56 menjadi 0.74. Peningkatan ini diperoleh melalui optimasi parameter ‘Random Forest’ dan penggunaan *class_weight='balanced'* sehingga model mampu menangani distribusi kelas yang tidak seimbang dengan lebih baik.

D. Analisis Feature Importance

Analisis *feature importance* dilakukan untuk mengetahui kontribusi masing-masing fitur hasil ekstraksi ‘MobileNetV3’ terhadap proses klasifikasi yang dilakukan oleh Random Forest. Sepuluh fitur dengan nilai *importance* tertinggi ditampilkan pada Tabel 6.

Tabel 6. Top-10 Feature Importance dari Model Random Forest

Ranking	Feature Index	Importance
1	789	0.007336
2	158	0.007191
3	652	0.005771
4	107	0.005714
5	221	0.005491
6	486	0.005438
7	102	0.005216

		8	84	0.005094	
		9	377	0.005080	
		10	16	0.005491	
Hasil analisis menunjukkan bahwa nilai <i>feature importance</i> tertinggi hanya mencapai sekitar 0.0073, sedangkan fitur lainnya memiliki nilai yang relatif berdekatan. Kondisi ini menunjukkan bahwa kontribusi fitur tersebar cukup merata pada keseluruhan 960 dimensi fitur yang dihasilkan ‘MobileNetV3’. Dengan demikian, proses klasifikasi tidak bergantung pada satu atau dua fitur tertentu, melainkan memanfaatkan kombinasi berbagai representasi visual yang telah dipelajari oleh model selama proses ekstraksi fitur. Karena fitur yang digunakan merupakan hasil ekstraksi ‘MobileNetV3’, setiap indeks fitur tidak memiliki interpretasi visual secara langsung. Oleh karena itu, <i>feature importance</i> pada penelitian ini digunakan untuk melihat kontribusi relatif fitur terhadap proses klasifikasi, bukan untuk mengidentifikasi karakteristik visual tertentu pada daun padi. Hasil tersebut menunjukkan bahwa model memanfaatkan kombinasi berbagai fitur yang saling melengkapi dalam membedakan 18 kelas penyakit daun padi.					
Kesimpulan dan Saran					
Kesimpulan	1. Penelitian ini berhasil mengembangkan model klasifikasi penyakit daun padi menggunakan kombinasi ‘MobileNetV3’ sebagai <i>feature extractor</i> dan ‘Random Forest’ sebagai <i>classifier</i>. Model yang dihasilkan mampu mengklasifikasikan 18 kelas penyakit daun padi dengan akurasi sebesar 81,68% dan <i>Macro F1-Score</i> sebesar 0,74, sehingga dapat digunakan sebagai alternatif deteksi penyakit tanaman secara otomatis. 2. Penggunaan ‘MobileNetV3’ <i>pre-trained</i> ‘ImageNet’ terbukti efektif dalam menghasilkan representasi fitur visual berdimensi 960 yang mampu membedakan berbagai karakteristik penyakit daun padi. Hasil ini menunjukkan bahwa pendekatan transfer learning dapat dimanfaatkan untuk meningkatkan efisiensi pengembangan sistem klasifikasi citra pada bidang pertanian. 3. Hasil evaluasi menunjukkan bahwa model memiliki performa yang baik pada sebagian besar kelas penyakit, terutama pada kelas dengan karakteristik visual yang khas seperti <i>Neck Blast</i>, <i>Grassy Stunt Virus</i>, dan <i>Tungro</i>. Namun demikian, performa model masih menurun pada beberapa kelas dengan jumlah data yang sangat sedikit dan memiliki kemiripan visual dengan kelas lain. 4. Faktor utama yang memengaruhi performa model adalah ketidakseimbangan jumlah data antar kelas (<i>class imbalance</i>) serta kemiripan pola gejala penyakit pada beberapa kategori daun padi. Kedua faktor tersebut menyebabkan model lebih sulit mengenali kelas-kelas minoritas dibandingkan kelas mayoritas.				

	5. Model yang dikembangkan berpotensi mendukung penerapan pertanian cerdas (<i>smart agriculture</i>) melalui proses identifikasi penyakit daun padi yang lebih cepat dan otomatis. Temuan ini dapat dimanfaatkan sebagai dasar pengembangan sistem deteksi penyakit berbasis komputer yang membantu petani melakukan identifikasi dini penyakit sehingga penanganan dapat dilakukan lebih cepat dan tepat.
Saran	1. Penelitian selanjutnya disarankan menerapkan teknik penanganan <i>class imbalance</i> yang lebih optimal, seperti SMOTE atau penambahan jumlah data pada kelas minoritas agar performa klasifikasi lebih merata pada seluruh kelas. 2. Penggunaan arsitektur <i>feature extractor</i> lain seperti EfficientNetV2, ConvNeXt, atau Vision Transformer (ViT) dapat dieksplorasi untuk memperoleh representasi fitur yang lebih kaya. 3. Penelitian berikutnya dapat melakukan <i>fine-tuning</i> pada beberapa lapisan 'MobileNetV3' sehingga model lebih mampu mempelajari karakteristik spesifik penyakit daun padi. 4. Model yang telah dikembangkan dapat diimplementasikan dalam bentuk aplikasi berbasis web atau perangkat mobile sehingga lebih mudah digunakan oleh petani dan praktisi pertanian. 5. Integrasi data citra dengan data lingkungan seperti suhu, kelembapan, dan curah hujan dapat diteliti untuk meningkatkan akurasi deteksi penyakit yang dipengaruhi faktor iklim. 6. Eksperimen menggunakan metode ensemble lain seperti XGBoost, LightGBM, atau stacking ensemble dapat dilakukan untuk memperoleh performa klasifikasi yang lebih baik.
Daftar Pustaka	
Daftar Pustaka	[1] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaria, M. A. Fadhel, M. Al-Amidie, dan L. Farhan, "Review of deep learning: Concepts, CNN architectures, challenges, applications, future directions," <i>Journal of Big Data</i>, vol. 8, no. 1, hal. 53, 2021. doi: 10.1186/s40537-021-00444-8. [2] J. Chen, J. Chen, D. Zhang, Y. Sun, dan Y. A. Nanekharan, "Using deep transfer learning for image-based plant disease identification," <i>Computers and Electronics in Agriculture</i>, vol. 173, hal. 105393, 2020. doi: 10.1016/j.compag.2020.105393. [3] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, dan H. Adam, "Searching for MobileNetV3," dalam <i>Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)</i>, Seoul, Korea, 2019, hal. 1314–1324. doi: 10.1109/ICCV.2019.00140.

- [4] M. T. Islam, M. N. Hoq, M. B. Hasan, dan M. A. Islam, "Rice leaf disease detection and classification using CNN-based features and random forest classifier," *Frontiers in Bioengineering and Biotechnology*, vol. 10, hal. 855667, 2022. doi: 10.3389/fbioe.2022.855667.
- [5] Y. Lu, S. Yi, N. Zeng, Y. Liu, dan Y. Zhang, "Identification of rice diseases using deep convolutional neural networks," *Neurocomputing*, vol. 267, hal. 378–384, 2017. doi: 10.1016/j.neucom.2017.06.023.
- [6] H. T. Rauf, B. A. Saleem, M. I. U. Lali, M. A. Khan, M. Sharif, dan S. A. C. Bukhari, "A citrus fruits and leaves dataset for detection and classification of citrus diseases through machine learning," *Data in Brief*, vol. 26, hal. 104340, 2019. doi: 10.1016/j.dib.2019.104340.
- [7] P. K. Sethy, N. K. Barpanda, A. K. Rath, dan S. K. Behera, "Deep feature based rice leaf disease identification using support vector machine," *Computers and Electronics in Agriculture*, vol. 175, hal. 105527, 2020. doi: 10.1016/j.compag.2020.105527.
- [8] C. Singha dan C. Mahanta, "Rice leaf disease classification using transfer learning," dalam *2021 IEEE Int. Conf. Electronics, Computing and Communication Technologies (CONECCT)*, Bangalore, India, 2021, hal. 1–5. doi: 10.1109/ECTIDAMTNCON51128.2021.9425696.
- [9] M. Wahabzada, A. K. Mahlein, C. Bauckhage, U. Steiner, E. C. Oerke, dan K. Kersting, "Plant phenotyping as a jackpot problem for machine learning for plant biologists," *Biosystems Engineering*, vol. 195, hal. 45–58, 2020. doi: 10.1016/j.biosystemseng.2020.03.020.
- [10] X. Zhang, Y. Qiao, F. Meng, C. Fan, dan M. Zhang, "Identification of maize leaf diseases using improved deep convolutional neural networks," *International Journal of Computing*, vol. 23, no. 4, hal. 30370–30377, 2018. doi: 10.47839/ijc.23.4.3773