

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Alya Nabila Tamam (24031554099)
Anggota 1	Fina Nihayatul Husna (24031554022)
Anggota 2	Juli Yawati Manalu (24031554050)
URL Github	https://github.com/alvanabilatamam/Projek-Machine-Learning

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Daun Padi Menggunakan Ekstraksi Fitur MobileNetV3 dan Random Forest untuk Mendukung Pertanian Berkelanjutan
Topik	Pangan
Pilihan Rumusan Masalah	1.3 Dampak Perubahan Iklim dan Rendahnya Adopsi Pertanian Berkelanjutan
Revisi	Ya

Deskripsi Rumusan masalah	Padi (<i>Oryza sativa L.</i>) merupakan salah satu komoditas pangan utama yang memiliki peran penting dalam memenuhi kebutuhan pangan masyarakat Indonesia. Produktivitas tanaman padi sangat dipengaruhi oleh kondisi lingkungan dan kesehatan tanaman. Salah satu permasalahan utama dalam sektor pertanian padi adalah munculnya berbagai penyakit daun seperti <i>Rice Blast</i>, <i>Brown Spot</i>, <i>Bacterial Leaf Blight</i>, <i>Leaf Scald</i>, dan <i>Hispa</i> yang dapat menurunkan kualitas serta hasil panen secara signifikan. Permasalahan ini menjadi semakin penting seiring dengan terjadinya perubahan iklim yang menyebabkan peningkatan suhu, perubahan pola curah hujan, dan kelembapan udara yang tidak stabil. Kondisi tersebut menciptakan lingkungan yang lebih mendukung perkembangan patogen tanaman sehingga risiko penyebaran penyakit pada tanaman padi semakin meningkat. Selain berdampak pada produktivitas pertanian, kondisi ini juga dapat memengaruhi ketahanan pangan dan kesejahteraan petani. Proses identifikasi penyakit daun padi saat ini masih banyak dilakukan secara manual melalui pengamatan visual oleh petani atau tenaga ahli pertanian. Cara tersebut membutuhkan pengalaman dan ketelitian yang tinggi serta memerlukan waktu yang cukup lama. Di beberapa daerah, keterbatasan jumlah tenaga ahli pertanian menyebabkan proses diagnosis penyakit tidak dapat dilakukan secara cepat sehingga penanganan tanaman sering terlambat dilakukan. Selain itu, kesalahan identifikasi penyakit dapat menyebabkan penggunaan pestisida yang kurang tepat dan berdampak pada peningkatan biaya produksi serta pencemaran lingkungan. Meskipun penelitian mengenai klasifikasi penyakit tanaman menggunakan <i>machine learning</i> dan <i>deep learning</i> telah banyak dilakukan, permasalahan ini belum sepenuhnya terselesaikan. Hal tersebut disebabkan oleh beberapa tantangan, seperti kemiripan gejala antar penyakit, variasi pencahayaan dan kualitas citra, serta kondisi dataset yang tidak seimbang pada setiap kelas penyakit. Selain itu, model <i>deep learning</i> dengan performa tinggi umumnya membutuhkan sumber daya komputasi yang besar sehingga kurang efisien untuk diterapkan pada perangkat dengan spesifikasi terbatas. Berdasarkan permasalahan tersebut, penelitian ini mengusulkan penggunaan MobileNetV3 sebagai <i>feature extractor</i> dan Random Forest sebagai <i>classifier</i> untuk melakukan klasifikasi penyakit daun padi secara otomatis. MobileNetV3 merupakan pengembangan terbaru dari keluarga MobileNet yang menggabungkan arsitektur MobileNetV2 dengan mekanisme <i>Squeeze-and-Excitation</i> (SE) serta fungsi aktivasi <i>h-swish</i>, sehingga menghasilkan performa yang lebih baik dengan efisiensi komputasi
---------------------------	--

	yang lebih tinggi. Kombinasi kedua metode tersebut diharapkan mampu menghasilkan model yang akurat, efisien, dan dapat membantu proses deteksi penyakit tanaman secara lebih cepat guna mendukung penerapan <i>smart agriculture</i> dan pertanian berkelanjutan.
Tujuan penelitian (Objectives)	Penelitian ini memiliki beberapa tujuan sebagai berikut: • Mengumpulkan dan mempersiapkan dataset citra daun padi dari berbagai kelas penyakit seperti <i>Rice Blast</i>, <i>Brown Spot</i>, <i>Bacterial Leaf Blight</i>, <i>Leaf Scald</i>, <i>Hispa</i>, <i>Narrow Brown Spot</i>, dan <i>Healthy</i> untuk proses pelatihan model klasifikasi. • Melakukan preprocessing citra meliputi resize gambar, normalisasi piksel, dan augmentasi data seperti rotasi, flip, zoom, dan <i>brightness adjustment</i> untuk meningkatkan kualitas dan variasi data latih. • Mengimplementasikan MobileNetV3 <i>pre-trained</i> dari ImageNet sebagai <i>feature extractor</i> untuk memperoleh fitur penting dari citra daun padi tanpa melakukan pelatihan CNN dari awal. • Melatih model Random Forest menggunakan <i>feature vector</i> hasil ekstraksi MobileNetV3 untuk melakukan klasifikasi multi-kelas penyakit daun padi. • Mengevaluasi performa model menggunakan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, <i>F1-score</i>, dan <i>confusion matrix</i> untuk mengetahui kemampuan model dalam mengklasifikasikan setiap kelas penyakit. • Menganalisis hasil klasifikasi model serta <i>feature importance</i> dari Random Forest untuk mengetahui fitur yang paling berpengaruh dalam proses klasifikasi penyakit daun padi.
Referensi penelitian	https://ieeexplore.ieee.org/document/10548108 https://doi.org/10.1109/ECTIDAMTNCON51128.2021.9425696 https://doi.org/10.1016/j.engappai.2025.111654 https://ieeexplore.ieee.org/document/10921634 https://doi.org/10.1016/i.compag.2023.108392


Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan dalam proyek ini bersumber dari repositori publik Kaggle yang bisa diakses melalui: Rice Leaf Disease: An Images Dataset . Proses akuisisi dilakukan dengan mengunduh data secara sekunder dimana data terdiri dari lebih kurang 30.000 citra digital daun padi. Data dikumpulkan dari berbagai sumber primer (lapangan dan laboratorium) untuk memastikan variasi kondisi pencahayaan dan latar belakang yang kemudian dikumpulkan dalam struktur folder sesuai label penyakitnya.		
Deskripsi awal fitur dataset	Dataset yang digunakan merupakan dataset citra (<i>image dataset</i>), bukan dataset tabular. Setiap data berupa file gambar daun padi yang telah dikelompokkan berdasarkan jenis penyakit tertentu. Adapun atribut awal pada dataset dijelaskan sebagai berikut:		
	Tabel 1. Deskripsi Fitur Dataset		
	Atribut	Tipe Data	Deskripsi
	File Citra	Image (JPG/PNG)	Foto daun padi dalam format citra digital dengan resolusi yang bervariasi. Pada tahap preprocessing, seluruh citra akan diubah ukurannya menjadi 224 ×224 piksel agar sesuai dengan input MobileNetV3.
	Label Kelas	Categorical (String)	Label kategori penyakit daun padi, seperti <i>Bacterial Leaf Blight</i> , <i>Brown Spot</i> , <i>Leaf Blast</i> , <i>Leaf Scald</i> , <i>Hispa</i> , <i>Narrow Brown Spot</i> , dan <i>Healthy</i> .
	Nama File	String	Nama unik untuk setiap file citra yang digunakan sebagai identitas data.
	Dimensi Piksel	Integer × Integer	Ukuran resolusi gambar dalam satuan piksel (lebar × tinggi) sebelum preprocessing.

	Channel Integer Jumlah kanal warna pada citra, yaitu RGB (<i>Red, Green, Blue</i>) dengan 3 channel warna. Direktori Folder/Path Struktur folder dataset yang mengelompokkan citra berdasarkan kelas penyakit untuk mempermudah proses loading data menggunakan framework deep learning.
Aspek khusus dari dataset	Karakteristik spesifik dataset citra ini akan dievaluasi melalui serangkaian tahapan analisis. Pertama, berkaitan dengan kepadatan data (<i>sparsity</i>), citra daun padi pada dasarnya bersifat padat karena seluruh elemen gambar memuat informasi warna dan bentuk yang lengkap. Meskipun demikian, penilaian lebih lanjut akan dilakukan pasca-ekstraksi menjadi vektor fitur oleh MobileNetV3 guna memastikan kelayakan data untuk pemrosesan oleh algoritma Random Forest. Kedua, ditemukan potensi ketidakseimbangan distribusi data (<i>imbalance</i>) akibat variasi jumlah sampel antar kelas penyakit. Sebagai tindak lanjut, analisis distribusi kelas akan dilaksanakan pada fase <i>Exploratory Data Analysis</i> (EDA). Strategi mitigasi mencakup penerapan pembagian data berstrata (<i>stratified split</i>) dan augmentasi data untuk membantu model mengenali setiap kelas secara lebih merata. Ketiga, pengendalian data penciran (<i>outlier</i>) akan difokuskan pada deteksi citra dengan anomali teknis, seperti kondisi pencahayaan ekstrem atau kehadiran objek irrelevant. Pendekatan-pendekatan ini diformulasikan secara terstruktur demi menjamin transparansi proses pra-pemrosesan data yang sesuai dengan standar penilaian ujian.

Rencana Metode

Teknik yang digunakan	Pada proyek ini digunakan pendekatan <i>supervised learning</i> karena proses pelatihan model dilakukan menggunakan data citra yang telah memiliki label kelas. Dalam implementasinya, digunakan kombinasi algoritma : a) MobileNetV3 CNN MobileNetV3 digunakan sebagai <i>feature extractor</i> untuk mengambil ciri penting dari citra daun padi. Model menggunakan bobot <i>pre-trained</i> dari 'ImageNet' dan bagian akhir model dihapus sehingga menghasilkan vektor fitur untuk setiap citra. MobileNetV3 hadir dalam dua varian, yaitu MobileNetV3-Large dan MobileNetV3-Small, yang masing-masing dapat dipilih sesuai kebutuhan komputasi dan akurasi yang diinginkan. b) Random Forest Hasil fitur digunakan sebagai input algoritma Random Forest untuk melakukan klasifikasi penyakit daun padi. Random Forest dipilih karena mampu meningkatkan akurasi klasifikasi dan mengurangi risiko <i>overfitting</i> melalui penggunaan banyak <i>decision tree</i> secara bersamaan.
Alasan pemilihan teknik/algoritma	Untuk mencapai hasil klasifikasi yang optimal, beberapa algoritma dipilih dengan mempertimbangkan keunggulan masing-masing dalam pengolahan citra dan penanganan data berdimensi tinggi. a) MobileNetV3 dipilih karena arsitekturnya yang lebih ringan dan efisien dibanding generasi sebelumnya. MobileNetV3 mengintegrasikan mekanisme <i>Squeeze-and-Excitation</i> (SE) yang memungkinkan model untuk memfokuskan perhatian pada channel fitur yang paling informatif, serta menggunakan fungsi aktivasi <i>h-swish</i> yang lebih efisien secara komputasi. Model ini sudah dilatih pada ImageNet sehingga mampu menyediakan representasi visual umum yang dapat langsung diadaptasi ke citra daun padi tanpa harus melatih CNN dari awal. b) Random Forest dipilih karena cocok untuk digunakan pada data yang berdimensi tinggi, tidak membutuhkan proses <i>scaling</i> fitur, serta secara alami memberikan informasi penting dari setiap fitur. Selain itu, algoritma ini relatif tahan terhadap <i>overfitting</i> dan memiliki waktu prediksi yang cepat. Pendekatan hybrid dipilih karena classifier tradisional seperti Random Forest dapat bekerja lebih stabil pada <i>feature vector</i> hasil ekstraksi CNN serta membutuhkan proses pelatihan yang lebih ringan dibanding <i>fine-tuning</i> CNN <i>end-to-end</i>.

	c) Kombinasi ekstraksi fitur CNN dengan classifier konvensional jauh lebih hemat sumber daya dibanding melatih CNN <i>end-to-end</i>. Pendekatan ini dapat dijalankan dengan perangkat keras terbatas.
Langkah-langkah umum pengerjaan	<pre>graph LR; Start([Start]) --> A[Pengumpulan Dataset dan EDA]; A --> B[Preprocessing Data]; B --> C[Augmentasi Data]; C --> D[Ekstraksi Fitur (MobileNetV3)]; D --> E[Pelatihan Model Random Forest]; E --> F[Evaluasi Model]; F --> G[Analisis Hasil]; G --> End([End]);</pre> Gambar 1. Tahapan Pengerjaan 1) Pengumpulan Data dan EDA Dataset citra daun padi diperoleh dari Kaggle. Tahap EDA dilakukan untuk melihat distribusi kelas, visualisasi sampel citra, ukuran gambar, dan mendeteksi kemungkinan <i>class imbalance</i>. 2) Preprocessing Data Seluruh citra diubah ukurannya menjadi 224×224 piksel dan dilakukan normalisasi nilai piksel ke rentang 0–1. Dataset kemudian dibagi menjadi data train, validation, dan test menggunakan <i>stratified split</i>. 3) Augmentasi Data Augmentasi dilakukan pada data train untuk meningkatkan variasi data dan mengurangi <i>overfitting</i>. Teknik yang digunakan meliputi rotasi, flip, zoom, shear, dan perubahan brightness. 4) Ekstraksi Fitur (MobileNetV3) Model MobileNetV3 pre-trained digunakan sebagai <i>feature extractor</i>. Lapisan akhir model dihapus dan output dari lapisan pooling menghasilkan <i>feature vector</i> untuk setiap citra. Varian MobileNetV3-Large digunakan untuk memaksimalkan representasi fitur dengan tetap mempertahankan efisiensi komputasi. 5) Pelatihan Model Random Forest Feature vector hasil ekstraksi digunakan sebagai input untuk melatih model Random Forest dalam melakukan klasifikasi penyakit daun padi. 6) Evaluasi Model Performa model dievaluasi menggunakan <i>accuracy</i>, <i>precision</i>, <i>recall</i>, <i>F1-score</i>, <i>macro-F1</i>, dan <i>confusion matrix</i> pada data testing. <i>Accuracy</i> digunakan untuk mengukur proporsi prediksi yang benar, sedangkan <i>precision</i> dan <i>recall</i> digunakan untuk mengevaluasi kemampuan model dalam mengidentifikasi setiap kelas penyakit. <i>F1-score</i> dan <i>macro-F1</i> digunakan untuk memberikan evaluasi yang seimbang pada kondisi data yang tidak merata antar kelas. Selain itu, <i>confusion matrix</i> digunakan untuk menganalisis pola kesalahan klasifikasi antar kelas penyakit. 7) Analisis Model Tahap akhir dilakukan analisis terhadap hasil klasifikasi, kesalahan prediksi, serta visualisasi <i>confusion matrix</i> untuk mengetahui performa model pada setiap kelas.